

Entrega 2 — Avances del ETL

Realizar el proceso ETL:

- Visualización de datos, análisis estadístico
- Análisis y comprensión de los datos, con la intención de analizar la calidad de los mismos (identificación de datos erróneos, faltantes, inconsistentes)
- Determinar la estrategia a seguir para cada caso (por ejemplo: eliminación, asignación de valores según algún criterio estadístico etc.)
- Unificación de fuentes externas, selección de columnas /filas.
- etc.
- Preparación del dataset objetivo.

Objetivo del proyecto

Predecir la etapa de sueño de una persona a partir de señales fisiológicas registradas mediante polisomnografía y un dispositivo wearable.

La variable objetivo es `Sleep_Stage`, con cinco clases:

- W: vigilia.
- N1: sueño ligero.
- N2: sueño intermedio.
- N3: sueño profundo.
- R: sueño REM.

Consideraciones

Alineación de epochs

Las etapas de sueño fueron anotadas por especialistas cada 30 segundos. Los CSV contienen 100 mediciones por segundo, por lo que cada ventana completa incluye 3000 filas.

Sin embargo, la primera fila del CSV no siempre coincide con el inicio de una ventana anotada. Ese desplazamiento varía entre pacientes. Por ejemplo, los cambios de etapa observados sugieren límites en las filas 2400, 5400, 8400... para S002, y en las filas 1100, 4100, 7100... para S004.

Agrupar desde la fila 0 puede mezclar partes de dos ventanas originales. En S002, el primer bloque de 3000 filas contiene 2400 muestras de vigilia (W) y 600 de N2.

Correcciones propuestas

Aspecto	Notebook original	Notebook nuevo
Ventanas de 30 segundos	Agrupaba cada 3000 filas desde la fila 0, después de limpiar.	Alinea las ventanas según el desplazamiento de cada paciente, antes de limpiar.
Control temporal	No comprobaba continuidad para formar las ventanas.	Revisa timestamps y separación de 0,01 segundos. Detiene el procesamiento si la alineación es

Aspecto	Notebook original	Notebook nuevo
	TP	ambigua.
Fragmentos incompletos	Excluía el último bloque incompleto.	Excluye y contabiliza fragmentos iniciales y finales.
Etiquetas inválidas	Eliminaba sus filas antes de agrupar, alterando las posiciones.	Conserva las posiciones; las etiquetas inválidas no participan en la moda y reducen la pureza.
SAO2	Aplicaba umbral, interpolación y relleno.	Conserva los valores originales; esas correcciones están desactivadas.
Valores extremos y nulos	Recortaba señales entre percentiles 1 y 99 y rellenaba faltantes.	Conserva extremos y faltantes hasta justificar su tratamiento.
Apneas	Generaba características y anulaba eventos cuando la etapa era W.	Excluye las características de anotaciones de apnea. Mantiene las señales respiratorias.
Estadísticas por epoch	Media, mediana y desviación estándar.	Mantiene las tres y agrega cantidad y proporción de mediciones no nulas por señal.
Auditoría	Informaba principalmente epochs descartados por pureza.	Registra desplazamiento, filas, fragmentos, epochs conservados, pureza y nulos por paciente.
Correlaciones	Incluía etapas codificadas como un orden numérico e identificadores.	Compara características estadísticas, excluyendo objetivo, identificadores y controles de calidad.
Selección de variables	Eliminaba y combinaba columnas directamente sobre la tabla principal.	Está desactivada; si se activa, trabaja sobre una copia experimental. Se eliminó la imputación global.

Qué comprobamos

Con el código actualizado se procesa **tres pacientes completos: 2257 epochs**, todos con una única etapa y sin nulos en la tabla resultante.

El cambio central es la preparación temporal y su auditoría. Todavía no entrenamos un modelo ni demostramos una mejora de precisión.

Estrategias para cada caso

Luego de analizar y comprender los datos (para verificar la calidad de los mismos), se pide **determinar una estrategia** para llevar a cabo en cada caso, no solamente mostrar gráficos.

 **Problema observado** → **evidencia** → **alternativas** → **decisión** → **resultado**

- **Conservar valores también puede ser una decisión justificada.** No hace falta eliminar o imputar para demostrar limpieza.
- **Las cuatro columnas de anotaciones de apnea quedan fuera del modelo.** No se consideran parte del estudio, solo se predice `Sleep_Stage`.
- Se utilizan tres pacientes para llevar a cabo el análisis rápidamente. Los pacientes serán: `S002`, `S004` y `S006`.

2.1. Dimensiones y tipos de datos

- **Objetivo:** comparar la estructura de los registros antes de unificarlos.
- **Evidencia:** S002, S004 y S006 tienen las mismas 32 columnas y tipos de datos. Sus registros contienen entre 1,96 y 2,41 millones de muestras, equivalentes a entre 5,44 y 6,70 horas a 100 Hz.
- **Decisión:** conservar nombres y tipos actuales; no se detectaron diferencias de estructura que requieran corrección.

- **Alcance:** tres registros completos. El resultado no garantiza que los otros 65 pacientes tengan la misma estructura ni que los valores sean correctos.

2.2. Análisis de etiquetas de sueño

- **Objetivo:** revisar las etiquetas de `Sleep_Stage`, su frecuencia y posibles valores faltantes o inválidos.
- **Evidencia:** no se encontraron etiquetas nulas ni inválidas. N2 es la etapa más frecuente en los tres pacientes. N3 no aparece en S002 y R no aparece en S004 ni S006.
- **Decisión:** conservar las etiquetas originales. No completar etapas ausentes ni balancear clases en esta sección; sus frecuencias se revisarán también por epoch.
- **Alcance:** tres registros completos. Los conteos representan muestras, no epochs ni episodios. Las anotaciones de apnea quedan fuera de este análisis.

Sección 2.3. Auditoría de valores faltantes e inválidos

- **Objetivo:** detectar nulos, infinitos y valores no numéricos en las señales fisiológicas.
- **Evidencia:** no se encontraron estos problemas en ninguna de las 26 señales de S002, S004 y S006.
- **Decisión:** no aplicar imputación ni eliminar mediciones por estos motivos.
- **Alcance:** tres registros completos, excluyendo anotaciones de apnea. Esta auditoría no evalúa extremos, señales constantes ni otros posibles artefactos.

2.3.1. Distribución e inspección de extremos


- **Objetivo:** revisar rangos y comportamiento temporal de HR, TEMP, EDA y SAO2 antes de definir tratamientos.
- **Evidencia:** los extremos de HR presentan cambios progresivos; TEMP muestra pequeñas fluctuaciones locales. SAO2 contiene escalones y valores entre 0,8085 y 0,9713. En EDA se observa un salto abrupto cerca del mínimo, cuya causa requiere revisión.
- **Decisión:** conservar los valores y mantener desactivado el recorte por percentiles. Revisar el salto de EDA antes de decidir si necesita corrección. Los gráficos no justifican eliminar extremos automáticamente.
- **Alcance:** registro completo de S002 y hasta 30 segundos alrededor de la primera aparición de cada mínimo y máximo. No confirma calidad fisiológica ni ausencia de artefactos en el resto del registro.

Gráfico de EDA (Actividad electrodérmica)

EDA es una variable que indica qué tan fácilmente la piel conduce electricidad. Cambia con la actividad de las glándulas sudoríparas. Cuanto mayor sea el valor, mayor conductancia de la piel habrá.

El eje vertical indica el valor de EDA. El eje horizontal muestra los segundos respecto al mínimo, donde 0 indica cuando aparece. El valor **mínimo** es el menor valor registrado en toda la columna EDA.

El gráfico muestra un cambio abrupto del nivel de la señal. Puede representar un cambio real o un problema de medición.



Sección 2.4. Preparación de epochs alineados

- **Objetivo:** formar ventanas completas de 30 segundos respetando la alineación de las etiquetas.
- **Evidencia:** S002 presenta un desplazamiento de 2400 muestras. Se obtuvieron 652 epochs de 3000 muestras; quedaron fuera 2400 muestras iniciales y ninguna final.
- **Decisión:** utilizar únicamente los epochs completos para el análisis posterior, contabilizando los fragmentos excluidos y conservando el registro original. La exclusión depende de la duración, no de la etapa de sueño.
- **Alcance:** esta sección prepara S002 como ejemplo exploratorio. La alineación de S004 y S006 también fue comprobada en el ETL de registros completos.

Sección 2.5. Evolución y transiciones del sueño

- **Objetivo:** comprobar la uniformidad de las etiquetas dentro de cada epoch y visualizar su evolución temporal. La dirección de transición es **fila** → **columna**: etapa anterior → etapa actual.
- **Evidencia:** los 652 epochs de S002 contienen una única etapa válida, con pureza del 100 % y sin empates de moda. Se contabilizaron 651 pares consecutivos. N3 no aparece en este registro.
- **Decisión:** conservar las etiquetas de los epochs y utilizar el hipnograma y la matriz para describir permanencias y cambios, sin imponer un orden numérico entre etapas.
- **Alcance:** epochs completos de S002. La matriz muestra conteos, no probabilidades ni ciclos completos de sueño; no permite concluir que las transiciones sean clínicamente normales o anormales.

Sección 2.6. Auditoría general de los 68 pacientes

2.6.1. Revisión de alineación y etiquetas faltantes

- **Objetivo:** localizar etiquetas inválidas y explicar las alertas de alineación.
- **Evidencia:** S027 presenta un tramo **Missing** de 850 segundos y desplazamientos de 1900 y 2900 muestras antes y después de ese tramo. S048 presenta desplazamientos de 0 y 2900, sin etiquetas inválidas. S089, S095 y S096 contienen un tramo **Missing** de 30 segundos cada uno.
- **Decisión:** conservar las posiciones originales y no imputar etapas. Mantener S027 y S048 pendientes de resolver su alineación antes de incorporarlos al ETL automático. En los registros con alineación consistente, los epochs sin etiquetas válidas no tendrán objetivo utilizable.
- **Alcance:** cinco registros completos. Los cambios observados permiten detectar diferencias de alineación, pero no confirmar su causa ni localizar exactamente el cambio en S048.

2.6.2. Revisión de rangos y comportamiento de SAO2

- **Objetivo:** investigar valores fuera del intervalo 0–1 usado como referencia exploratoria y epochs con oximetría media cercana a cero.
- **Evidencia:** 56 pacientes presentan muestras fuera de ese intervalo. En S004 y S006 se observan cambios abruptos entre niveles próximos a 1 y 0, con oscilaciones negativas y superiores a 1. En S027, toda la señal permanece alrededor de 12. No se encontraron ceros exactos.
- **Decisión:** conservar los archivos originales y no aplicar recortes, interpolaciones ni conversiones de escala sin justificación. Se propone excluir SAO2 y sus características de la primera versión del

dataset del modelo, hasta validar su interpretación. Esta exclusión todavía no está implementada.

- **Alcance:** auditoría de rangos de los 68 pacientes e inspección temporal de S004, S006 y S027. No se confirmó la causa de las anomalías.

Contraste con los metadatos

`Metadata.txt` describe SAO2 en porcentaje, pero no documenta una conversión al intervalo 0–1 ni explica los valores observados en S027. La documentación de DREAMT confirma el remuestreo de las señales PSG a 100 Hz; no se dispone del código exacto que generó los CSV utilizados.

Por lo tanto, no hay evidencia suficiente para reconstruir o corregir la señal. **Excluirla provisionalmente permite avanzar con las demás señales sin introducir una transformación arbitraria.**

Fuentes: `Metadata.txt` del dataset y [documentación de DREAMT 2.2.0](#).

2.6.3. Revisión de señales constantes

- **Objetivo:** identificar señales sin variación durante todo el registro y tramos constantes prolongados que puedan afectar las características por epoch.
- **Evidencia:** S097 presenta 18 señales completamente constantes. IBI permanece constante durante todo el registro en S026, S030, S036, S046 y S097; también presenta tramos extensos en otros pacientes. Se encontraron tramos de al menos 30 segundos en varias señales del wearable.
- **Decisión:** no eliminar automáticamente los tramos constantes. Mantener pendiente el tratamiento de las señales PSG de S097 y de IBI antes de generar el dataset definitivo. No reconstruir variaciones mediante imputación sin evidencia.
- **Alcance:** auditoría de las 26 señales de los 68 pacientes. Se registra el mayor tramo constante por señal y paciente; el umbral de 30 segundos es exploratorio. La constancia no confirma su causa ni implica que todos esos tramos sean errores.

2.6.4. Revisión de diferencias en EDA

- **Objetivo:** comparar rangos y evolución temporal de EDA, considerando el movimiento como contexto antes de definir tratamientos.
- **Evidencia:** los máximos son 1,70 μS en S002, 53,17 μS en S004 y 57,67 μS en S057. S004 presenta niveles elevados durante una parte extensa del registro; S057 muestra una subida pronunciada seguida de un descenso prolongado. Los mayores cambios locales de S002 y S004 coinciden con variaciones del acelerómetro; en S057 no se observa movimiento comparable en el intervalo inspeccionado.
- **Decisión:** conservar EDA sin recorte automático por percentiles. Los valores elevados y el movimiento coincidente no bastan para confirmar errores ni justificar un umbral general de eliminación.
- **Alcance:** comparación de máximos de los 68 pacientes e inspección detallada de S002, S004 y S057. Se analizaron hasta 60 segundos alrededor del máximo y del mayor cambio entre muestras; ambos pueden ocurrir en momentos distintos. La causa de los comportamientos observados no quedó confirmada.

Sección 3. Preparación y evaluación del dataset de epochs

...

3.1. ETL y generación de epochs

...

...

3.3. Distribución por etapa y paciente

- **Objetivo:** comparar la frecuencia de las etapas y la distribución de las características estadísticas entre pacientes.
- **Evidencia:** N2 predomina en los tres registros. R aparece únicamente en S002; N3 está ausente en S002 y tiene un solo epoch en S004. Las características presentan diferencias entre pacientes, especialmente EDA. También aparecen valores de SAO2_mean cercanos a cero en S004 y S006.
- **Decisión:** conservar las características y no balancear clases ni eliminar extremos automáticamente. Revisar las diferencias de EDA y los epochs con SAO2_mean cercano a cero sobre las señales originales antes de definir tratamientos.
- **Alcance:** 2257 epochs completos y puros de S002, S004 y S006. Los gráficos describen asociaciones; no demuestran errores, causas ni capacidad predictiva.

Cómo leer los gráficos

1. Barras: distribución de etapas

- **Eje horizontal:** paciente.
- **Eje vertical:** porcentaje de sus epochs.
- **Color:** etapa de sueño.

Una barra más alta indica mayor presencia de esa etapa. Por ejemplo, N2 representa aproximadamente el 51 % de S002, el 53 % de S004 y el 36 % de S006.

Las etapas tienen frecuencias desiguales y algunas están ausentes. Esto debe considerarse posteriormente al entrenar y evaluar el modelo.

2. Diagramas de caja: lectura general

Cada gráfico corresponde a una característica y un paciente. Cada caja reúne los valores de los epochs de una etapa.

- **Eje horizontal:** etapa.
- **Eje vertical:** valor de la característica.
- **Línea dentro de la caja:** mediana.
- **Caja:** 50 % central de los valores.
- **Bigotes:** se extienden hasta los valores más alejados dentro de 1,5 rangos intercuartílicos desde la caja.
- **Puntos exteriores:** valores fuera de los bigotes; requieren contexto, no son errores confirmados.

Las columnas corresponden a S002, S004 y S006. Cada fila comparte escala vertical para facilitar la comparación entre pacientes.

Una categoría vacía indica ausencia de epochs. En N3 de S004 aparece una línea porque existe una sola observación: no permite caracterizar su variabilidad.

3. HR_mean: frecuencia cardíaca media por epoch

S004 presenta valores generalmente mayores que S002 y S006. Dentro de cada paciente, varias cajas se superponen.

Esto muestra diferencias individuales y sugiere que μ_{p,HR_mean} , por sí sola, no separa claramente todas las etapas.

4. TEMP_mean: temperatura media por epoch

Las temperaturas y su dispersión varían entre pacientes. En S002, la mediana de N2 es mayor que la de W y N1; ese patrón no se repite de la misma forma en todos.

Una relación observada en un paciente no debe generalizarse automáticamente.

5. EDA_mean: actividad electrodérmica media por epoch

S004 presenta valores mucho mayores y más dispersos que S002 y S006. La escala compartida hace que las cajas de estos últimos parezcan casi planas.

Esta diferencia requiere revisar rangos, unidades y comportamiento temporal. No permite concluir directamente que los valores sean incorrectos.

6. BVP_std: variabilidad de amplitud por epoch

Una desviación estándar mayor indica mayor dispersión de los valores de BVP dentro de los 30 segundos; no representa directamente frecuencia cardíaca.

En S002, W y N1 muestran mayor dispersión entre epochs que N2. Existen puntos alejados en varias etapas, que requieren inspección temporal antes de considerar su eliminación.

7. SAO2_mean: oximetría media por epoch

S006 concentra la mayoría de sus valores cerca de 1. S002 y S004 presentan niveles centrales menores. En S004 y S006 aparecen algunos epochs de W con medias cercanas a cero.

Esos casos requieren localizar los epochs y revisar las mediciones originales: la auditoría de nulos no los detecta porque cero es un valor numérico.