

Resumen de los cambios y estado del TP

Te paso el notebook y la documentación. El objetivo sigue siendo **predecir la etapa de sueño** (**`**Sleep_Stage**`**). Cada fila del dataset preparado representa un epoch de 30 segundos; sus características son estadísticas calculadas sobre las señales.

Qué corregimos del notebook original

- **Ventanas temporales:** agrupar desde la primera fila podía mezclar etapas. Ahora se determina el desplazamiento de cada paciente antes de formar ventanas de 3000 muestras a 100 Hz.
- **Etiquetas inválidas:** se conservan sus posiciones para no alterar el tiempo. El ETL final admite únicamente ventanas completas con las 3000 etiquetas válidas e iguales.
- **Limpieza automática:** se desactivaron el recorte por percentiles, la interpolación y el relleno general. Primero revisamos la evidencia; un extremo no implica un error.
- **Apneas:** sus anotaciones quedan fuera de los predictores. Las señales respiratorias sí se conservan.
- **Características:** mantenemos media, mediana y desviación estándar; agregamos cantidad de muestras válidas y proporción de faltantes como controles de cobertura.
- **Correlaciones:** excluyen objetivo, identificadores y controles de calidad. La eliminación o combinación automática de características está desactivada.

Dónde encontrar cada cosa

Sección	Contenido
1	Carga y funciones compartidas, especialmente <code>definir_epochs</code> .
2.1–2.5	Exploración inicial y explicación del funcionamiento de los epochs.
2.6	Auditoría general de los 68 pacientes.
2.6.1	Alineaciones inconsistentes y etiquetas inválidas.
2.6.2	Problemas de escala y comportamiento de SAO2.
2.6.3	Señales constantes, especialmente IBI y S097.
2.6.4	Diferencias de EDA e inspección temporal.
3.1–3.2	Generación y resumen del dataset preparado.
3.3–3.5	Gráficos por paciente, correlaciones y propuestas experimentales de características.

Los gráficos de distribución se trasladaron a **3.3** porque necesitan la tabla generada en **3.1**.

Decisiones tomadas para avanzar

La auditoría leyó los 68 archivos sin errores y no encontró nulos, infinitos ni valores no numéricos en las señales. Sin embargo, identificó problemas que esos controles no detectan.

Para esta primera versión:

- **S027 y S048:** pendientes por alineación inconsistente.
- **S097:** pendiente por múltiples señales PSG constantes.
- **SAO2 e IBI:** excluidas provisionalmente de las características por los problemas encontrados.
- **EDA:** conservada; los valores elevados y el movimiento coincidente no confirman por sí solos errores.

Estas decisiones permiten avanzar sin inventar correcciones ni reconstruir mediciones.

Resultado actual

El ETL ya se ejecutó sobre 65 pacientes: generó 49.062 epochs y 126 columnas, sin nulos en la tabla resultante. Descartó tres epochs por etiquetas inválidas.

Los archivos están en `/kaggle/working/etl_v1/`, incluido `dataset_epochs_v1.csv`, junto con las auditorías y exclusiones.

Las 126 columnas incluyen características, metadatos y controles: **no todas entrarán al modelo.**

Qué falta

Actualizar la documentación de la sección 3 y definir los predictores. Después, separar entrenamiento y evaluación **por paciente** y avanzar con el modelado.

Hay texto desactualizado en 3.6: todavía menciona un filtro de pureza del 60 %, una prueba pequeña y que el dataset no fue generado. El código actual de 3.1 exige pureza del 100 % y ya produjo el resultado indicado arriba. El PDF también necesita reflejar este avance.